워커힐 WISE 정책 비교 시뮬레이션

부속서 5 — 2단계 제안: 실제 모델 검증과 논지 재구성

항목	내용
문서 성격	2단계 범위 제안
근거	1단계 오라클 스윕 24시드
기간	2주
요청	API 접근, 예산 상한, 모델 지정

---

0. 한 문장

1단계는 **측정 장치가 작동한다는 것**을 보였고, 2단계는 그 장치가 **실제 모델에서도 작동하는지**를 확인합니다. 이 확인 없이는 어떤 수치도 대외에 인용할 수 없습니다.

1. 1단계에서 확정된 것

항목	결과
기준 순위 대비 측정	작동 (9정책 36쌍)
안정화 비용 측정	작동
판정 3단계·기권 처리	작동
회귀 테스트	17개 통과
재현성 해시	규칙·시드 고정

2. 확정되지 않은 것 — 오라클의 한계

오라클 스윕 24시드 결과입니다. 방향 적중률 격차(A−B):

이질성	격차	95% CI
1×	+0.0127	[−0.0012, +0.0266]
3×	+0.0636	[+0.0423, +0.0850]
10×	+0.0336	[+0.0175, +0.0496]

교차는 관측되지 않았습니다. 그러나 이 결과를 "교차 없음"으로 읽으면 안 됩니다. **오라클이 논지를 기각한 것이 아니라**, 오라클이 논지를 시험할 수 없다는 것을 보인 것입니다.

이유는 명확합니다. 오라클은 편향이 없습니다. 실제 모델의 실패는 편향에서 나옵니다. 확률을 체계적으로 부풀리거나, 가격에 과민하게 반응하거나, 페르소나 속성을 무시하는 방식으로 틀립니다. 오라클에는 그런 오류가 없으므로, 두 계약의 차이는 양자화 잡음만 남습니다.

따라서 1단계의 94.4%라는 수치는 **오라클의 수치**입니다. **실제 모델 없이는 확인할 수 없습니다.** 이 수치를 고객 제안서의 성능 근거로 인용하면, 검증되지 않은 숫자가 계약 문서에 들어갑니다.

3. 2단계가 답할 질문

질문	측정 방법
실제 모델에서 A 우위가 유지되는가	동일 9정책 격자 재실행
편향이 계약별로 다르게 작용하는가	계약 × 이질성 격차 신뢰구간
기권 게이트가 오결론을 실제로 줄이는가	게이트 on/off 비교
안정화 비용이 예산 안에 들어오는가	호출 수 대비 순위 고정 시점

4. 재구성된 논지

교차 가설을 버리고 측정 장치를 기여로 세웁니다.

기여	내용	근거
기준 순위 기반 충실도	예측 적합도가 아니라 순위 정확도로 평가	1단계 측정 작동
동일 예산 계약 비교	정확도 + 안정화 비용 동시 보고	1단계 측정 작동
검정력 요구량	36쌍에서 SE 0.050, 3%p 판별에 24시드	24시드 실측

세 번째가 실무적으로 가장 유용합니다. 정책 비교 시뮬레이션을 도입하려는 조직이 가장 먼저 부딪히는 질문이 "몇 번 돌려야 결론이 서는가"인데, 이에 대한 정량 답을 주는 연구는 없습니다.

5. 규모와 비용

규모는 셀 설계에서 계산합니다. 셀당 400건, 45셀이면 정책당 판정 18,000건이고, 20명을 한 번에 처리하면 정책당 900회 호출입니다.

단계	호출 수	소형 모델	중형 모델
파일럿 (2정책 × 2계약)	3,600	약 $0.3	약 $5
본실험 1시드 (54구성)	48,600	약 $4	약 $73
본실험 8시드	388,800	약 $35	약 $583
완전 검정력 24시드	1,166,400	약 $105	약 $1,749

가정: 정책 9개 × 계약 2종 × 이질성 3수준 = 54구성. 호출당 입력 400토큰, 출력 50토큰.

권고는 **파일럿 + 8시드**입니다. 완전 검정력은 파일럿에서 교차 징후가 확인된 경우에만 집행합니다. 먼저 약 $35로 방향을 확인하고, 살아 있으면 확장합니다.

6. 실패해도 남는 것

교차가 실제 모델에서도 나오지 않더라도 다음은 남습니다.

잔여물	고객 관점 가치
측정 장치	어떤 정책 비교 도구든 검증 가능
안정화 비용 산식	예산 산정 근거
검정력 계산	반복 횟수 결정 근거
파일럿 하네스	재사용 가능한 코드

잔여물	고객 관점 가치
기권 규칙	무리한 결론 방지

실패해도 남는 것이 있습니다. 오히려 "교차 없음"이 확인되면, 확률을 요구하지 않는 계약을 표준으로 삼을 근거가 생깁니다. 그것도 계약 설계에 쓸 수 있는 결과입니다.

7. 결정 요청

결정이 필요한 것은 세 가지입니다.

#	요청	사유
1	모델 API 접근	실측 없이는 검증 불가
2	예산 상한 (약 $35~$590)	초과 집행 방지
3	사용 모델 지정	재현성 해시에 포함

2주 일정으로 파일럿과 8시드를 완료하고, 결과에 따라 24시드 확장 여부를 별도로 판단합니다.